

Per-gloss instance count vs. recognition F1 score

